

Eksploracja danych

Laboratorium 1

Przygotowanie danych

- ▶ W ramach pierwszego laboratorium należy przygotować wstępnie własny zbiór danych
- ▶ (zbiór danych dowolny, można pobrać z <https://archive.ics.uci.edu/ml/index.php>).
- ▶ Zbiór około 1000 wierszy i powyżej 10 kolumn. W zbiorze danych należy wprowadzić po 5% braków w danych i 5% danych odstających.

Eksploracja danych

- ▶ Eksploracja danych (data mining / data exploration):
 - ▶ odkrywanie wzorów, zależności, anomalii w danych
 - ▶ przygotowanie danych do modeli ML/statystycznych
- ▶ Pierwszy krok: zrozumieć dane, nie od razu „trenować model”

Typy zmiennych



- ▶ Numeryczne:
 - ▶ ciągłe (np. wzrost, temperatura)
 - ▶ dyskretne (np. liczba zakupów)
- ▶ Kategoryczne:
 - ▶ nominalne (np. kolor: red/green/blue)
 - ▶ porządkowe (np. ocena: low/medium/high)
- ▶ Od typu zmiennej zależy:
 - ▶ jakie statystyki mają sens
 - ▶ jakie metody preprocessingu stosujemy

Podstawowe statystyki opisowe

- ▶ Dla zmiennych numerycznych:
 - ▶ Średnia arytmetyczna - „typowa” wartość
 - ▶ Mediana - środkowa wartość (odporna na skrajności)
 - ▶ Kwartyle, percentyle - podział rozkładu
 - ▶ Minimum, maksimum, rozstęp





Podstawowe statystyki opisowe

- ▶ Miary zmienności:
 - ▶ Wariancja, odchylenie standardowe - jak bardzo dane są „rozsypane”
 - ▶ IQR (interquartile range) - rozstęp między Q1 a Q3
- ▶ Rozkład:
 - ▶ Skośność (skewness) - czy ogon jest w lewo/prawo
 - ▶ Kurtoza - „spiczastość” rozkładu



Wizualizacja podstawowa


- ▶ Histogram - rozkład zmiennej numerycznej
- ▶ Wykres pudełkowy (boxplot) - mediana, kwartyle, potencjalne outliery
- ▶ Wykres punktowy (scatter) - związek dwóch zmiennych
- ▶ Dla zmiennych kategoriycznych:
 - ▶ wykres słupkowy (liczebności kategorii)



Brakujące dane

- ▶ Reprezentowane jako: NaN, puste pola, specjalne kody (-1, 999)
- ▶ Problem:
 - ▶ zaburzają statystyki, mogą psuć modele
- ▶ Strategie:
 - ▶ usunięcie rekordów/kolumn (ostrożnie!)
 - ▶ Uzupełnienie braków:
 - ▶ średnia/mediana/moda
 - ▶ bardziej zaawansowane metody

Wartości odstające



- ▶ Obserwacje „daleko” od reszty danych
- ▶ Źródła:
 - ▶ błąd pomiaru / wprowadzania
 - ▶ rzeczywiste rzadkie zdarzenia
- ▶ Wpływ:
 - ▶ przekłamanie średniej, regresji, skalowania
- ▶ Proste wykrywanie:
 - ▶ boxplot, IQR, progi (np. $\pm 3\sigma$)

Wykrywanie wartości odstających

- ▶ Metoda Z-score

$$Z = \frac{x - \bar{x}}{\sigma}$$

- ▶ Z-score > 3 lub < -3 uznawane za wartości odstające (outliers).

Wykrywanie wartości odstających

- ▶ Metoda kwartylowa

Q1 - pierwszy kwartyl

Q3 - trzeci kwartyl

$IQR = Q3 - Q1$

Wartość jest daną odstającą jeśli $< Q1 - 1,5 * IQR$, lub $> Q3 + 1,5 * IQR$

Preprocessing

- ▶ Większość algorytmów zakłada coś o danych:
 - ▶ podobne skale cech
 - ▶ brak braków
 - ▶ sensowny kodowanie kategorii
- ▶ Cel preprocessingu:
 - ▶ zrobić z danych „pokarm dla algorytmów”, nie zmieniając sensu informacji

Skalowanie i normalizacja

- ▶ Dla cech numerycznych:
 - ▶ Standardyzacja (Z-score):

$$z = \frac{x - \mu}{\sigma},$$

- ▶ średnia ≈ 0 , odchylenie ≈ 1
 - ▶ Skalowanie min-max :
 - ▶ przeskalowanie do $[0, 1]$
- ▶ Ważne dla:
 - ▶ metod opartych na odległości (kNN, k-means)
 - ▶ sieci neuronowych, SVM itp.

Zmienne kategoryczne - kodowanie

- ▶ Algorytmy oczekują liczb → potrzebne zakodowanie kategorii:
 - ▶ Label encoding:
 - ▶ każdej kategorii przypisujemy liczbę (0,1,2,...)
 - ▶ uwaga na sztuczną „kolejność”
 - ▶ One-Hot encoding:
 - ▶ nowa kolumna dla każdej kategorii (0/1)
 - ▶ standard dla większości modeli liniowych / drzew